

# Fire Detection with Machine Learning techniques

Author(s) : Alessandro Giovannini (520310), Davide Costa (489360)

Corso : Machine Learning e Sistemi Intelligenti A.A. 2021/2022

Università : Università degli studi Roma TRE

Github : <https://github.com/DavideCosta95/FireDetection-ML>



**Keywords:** Artificial Intelligence, Machine Learning, Drone, CNN, Transfer Learning, Incendio, Natura

## ABSTRACT

In questo studio vengono confrontate le performance di una rete la cui architettura è stata definita allo scopo della rilevazione di incendi all'interno di immagini, addestrata da zero, con quelle di una rete in cui è stata utilizzata la tecnica del transfer learning. Il concetto alla base del transfer learning è che utilizzando un modello addestrato su un set di dati sufficientemente ampio e generale, fungerà efficacemente da modello generico da cui fare feature extraction. Questo documento è organizzato come segue. La Sezione 2 discute l'uso delle tecnologie utilizzate per la realizzazione del progetto. La Sezione 3 fornisce una descrizione dettagliata dei dataset analizzati, seguita dalla descrizione dell'architettura, nella Sezione 4. Nella Sezione 5 sono stati discussi i risultati ottenuti e confrontate le reti. Nella Sezione 6 sono stati proposti scenari e sviluppi futuri del progetto. La Sezione 7 contiene osservazioni conclusive.

tipo, ogni edificio o veicolo per il trasporto pubblico è dotato di sistemi di protezione antincendio, questi sistemi sono costituiti principalmente da rilevatori termici e di fumo che devono essere installati in prossimità delle probabili fonti di incendio; in caso contrario, potrebbero facilmente fallire, non essendo in grado di rilevarlo. La rivelazione di incendi basata su immagini potrebbe presentare notevoli vantaggi rispetto ai metodi tradizionali, come risposte e interventi potenzialmente rapidi e ampie aree di rilevamento e copertura. Il modello proposto utilizza un approccio di elaborazione e classificazione delle immagini tramite reti neurali convoluzionali (CNN). L'obiettivo del presente studio è ottenere una rete che possa essere installata su dispositivi mobili, come droni, al fine di rilevare incendi in aree boschive e in ambienti naturali. La rete sviluppata, inoltre, deve essere di dimensioni sufficientemente ridotte da poter essere utilizzata su hardware a bassa potenza, utilizzabile su dei droni.

## CONTENTS

Contents	1
1 Introduzione	1
2 Tecnologie utilizzate	1
3 Descrizione del dataset	2
4 Architettura delle reti	2
5 Risultati ottenuti	3
5.1 Risultati rete ad hoc . . . . .	3
5.2 Risultati rete con transfer learning . . . . .	4
5.3 Efficacia approcci proposti . . . . .	4
6 Sviluppi futuri	5
7 Conclusioni	5
References	6

## 1 INTRODUZIONE

L'incendio è uno dei principali rischi che mette in pericolo la vita umana, l'economia e l'ambiente. Ciò può portare numerose perdite e gravi danni alle apparecchiature e alla natura che ci circonda, oltre che alla salute personale. È estremamente essenziale mettere in atto meccanismi avanzati di risposta alle catastrofi al fine di salvaguardare il nostro ecosistema da incendi. A causa del rapido aumento di eventi di questo



**Figure 1.** Esempio di drone: DJI Matrice 210 RTK

## 2 TECNOLOGIE UTILIZZATE

Il progetto è stato interamente realizzato in Python, la scelta è dipesa dalle librerie improntate nel Machine Learning e per l'IA in generale che il linguaggio offre. La principale libreria utilizzata è Keras con backend Tensorflow. Grazie ad entrambe è possibile facilmente realizzare una CNN, ossia Convolutional Neural Network. Keras è l'API di alto livello di TensorFlow: un'interfaccia accessibile e altamente produttiva per la risoluzione di problemi di machine learning, con particolare attenzione al deep learning moderno. Fornisce astrazioni essenziali ed elementi costitutivi per lo sviluppo di sistemi di apprendimento automatico con un'elevata velocità di iterazione. La scelta di Keras è dovuta all'estrema facilità di utilizzo e l'efficacia che ha mostrato durante lo svolgimento del progetto. Nella [Figure 1] sono rappresentate graficamente le caratteristiche delle librerie e la loro relazione. Anche nell'ambito del transfer learning Keras ricopre un ruolo importante, in quanto fornisce un accesso semplice e comodo a una molteplicità di

modelli di rete neurale differenti, ad alta capacità prestazionale nelle attività di riconoscimento delle immagini.

Il processo di transfer learning con Keras può riassumersi nei seguenti 5 macro-passaggi:

- 1) Esaminare e comprendere i dati;
- 2) Costruire una pipeline di input e pre-processing delle immagini;
- 3) Caricare il modello base pre-addestrato, con i relativi parametri e pesi degli archi, creando ulteriori strati sopra quelli esistenti;
- 4) Allenare il modello di rete neurale ottenuto;
- 5) Valutare il modello e la sua efficacia.

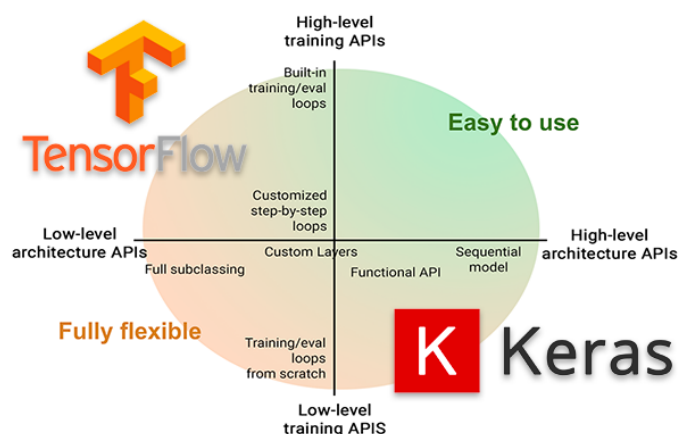


Figure 2. Librerie a confronto [1]

### 3 DESCRIZIONE DEL DATASET

Il dataset [2] utilizzato è costituito da 1832 immagini di fuoco relative ad aree boschive e naturali in generale. Il soggetto predominante nell'immagine è il fuoco, con esposizione, luminosità e inquadratura ottimali per un riconoscimento diretto. Nel dataset sono presenti esempi di fumo ma quasi sempre accompagnati dalla presenza contestuale del fuoco. Sono presenti elementi naturali e antropici, tra cui figure umane, con però sempre una componente naturale predominante. Simmetricamente, gli esempi di non-fuoco nel dataset sono con le medesime caratteristiche di tipologia di soggetti presenti.



Figure 3. Estratto di esempio dal dataset

Il training set e il validation set sono stati divisi con un rapporto di 80-20, applicando random shuffling e introducendo nella pipeline di data ingestion anche una componente di data augmentation, con effetti come random flip e random contrast. Il test set è invece composto da 38522 immagini estratte da video ripresi in situazioni meno controllate, con inquadrature e caratteristiche di normalizzazione della luminosità e del contrasto non omogenee. Si è scelto questo approccio per due

motivi: 1) La bassa disponibilità di esempi relativi al dominio specifico di questo studio e l'abbondanza di immagini generiche di fuoco, anche per espandere il dataset di addestramento; 2) Verificare la possibilità di un transfer learning concettuale, cioè il poter utilizzare una rete che ha appreso il riconoscimento del fuoco in senso generale per riconoscere delle istanze di fuoco di un dominio ben preciso e specifico.

### 4 ARCHITETTURA DELLE RETI

La rete ottenuta con transfer learning è basata sull'architettura VGG-16 con un ulteriore strato aggiuntivo, costituito da un unico neurone fully connected allo strato precedente, ed è solo questo strato aggiuntivo che è stato addestrato con il dataset di cui sopra.




Figure 4. Architettura di rete VGG-16

L'architettura della rete sviluppata nell'ambito di questo studio è illustrata di seguito. La dimensione delle immagini è 180x180, con una batch size = 32, utilizzando layer di convoluzione 2D con kernel di dimensione crescente, potenze di 2, come illustrato in [Fig. 5]. In particolare, viene ripetutamente applicato lo stesso segmento di rete, modificando ad ogni iterazione la dimensione del kernel dei layer di convoluzione.

Al layer di input viene applicato un processo di data augmentation che modifica alcune caratteristiche delle immagini di input, come l'orientazione, la dimensione, il contrasto e luminosità.

L'ultimo layer è quello di output ed è costituito solo da un neurone, essendo un classificatore binario, fully connected con lo strato precedente, utilizzando la sigmoide come funzione di attivazione. Nell'ambito della rete vengono inoltre utilizzati a più riprese layer di dropout, batch normalization e max pooling.

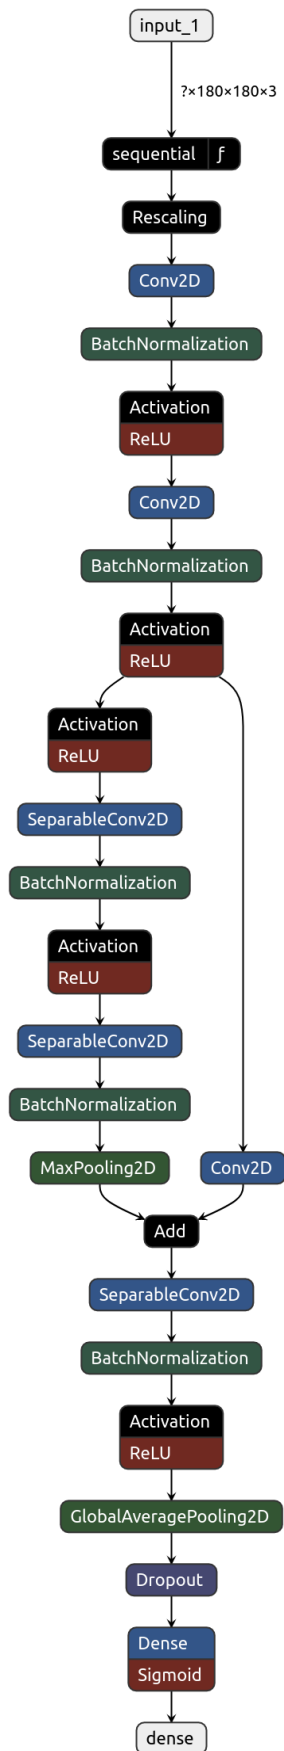


Figure 5. Architettura della rete progettata ad hoc [3]

## 5 RISULTATI OTTENUTI

In questa sezione verranno esposti i risultati ottenuti con le due reti descritte in precedenza.

### 5.1 Risultati rete ad hoc




Figure 6. Accuracy addestramento rete ad hoc[1]

Durante le prime epoche l'accuracy sul validation set rimane molto basso, per poi avere un repentino incremento verso la decima epoca. Da quel punto in poi, la rete mostra una capacità di apprendimento molto elevata, che rimane pressoché stabile attorno a 0.95, indicando in 30 un numero sufficiente di epoche.




Figure 7. Loss addestramento rete ad hoc

L'andamento della loss risulta ricco di spike ma mostra una tendenza decrescente, indice della buona approssimazione del modello.

## 5.2 Risultati rete con transfer learning




Figure 8. Accuracy addestramento con transfer learning

Come è possibile evincere dal grafico del processo di training, la rete ha raggiunto ottimi risultati sul validation set, mostrando un andamento asintotico rispetto ad 1 e, al netto di fluttuazioni minori, a derivata sempre positiva. Lo scarto di accuracy tra le ultime epoche è dell'ordine di  $10^{-3}$ , ciò ha condotto alla scelta del numero di epoche, fissato a 30.




Figure 9. Loss addestramento con transfer learning

Anche per quanto riguarda la loss si denota un andamento strettamente decrescente ed asintotico rispetto allo zero.

## 5.3 Efficacia approcci proposti

Metriche rete con transfer learning :

Metrica	FUOCO	NO FUOCO
Precision	0.69	0.65
Recall	0.55	0.77
F1-score	0.61	0.70

<b>ACCURACY</b>	0.66
-----------------	------

Metriche rete ad hoc :

Metrica	FUOCO	NO FUOCO
Precision	0.83	0.81
Recall	0.79	0.85
F1-score	0.81	0.83

<b>ACCURACY</b>	0.82
-----------------	------

Come si evince dalle metriche di entrambe le reti, il punto di forza è il riconoscimento del non-fuoco, indicato dal valore di recall per la corrispondente classe.

L'approccio con transfer learning mostra performance inferiori, se ne deduce che non è conveniente usarlo in questo contesto. Un'ipotesi per spiegare questo comportamento potrebbe essere il cosiddetto "vanishing gradient problem", "scomparsa del gradiente". Il gradiente assume un valore nullo o asintotico allo zero impedendo così l'aggiornamento dei pesi. La velocità di apprendimento dei parametri dei neuroni diventa sempre più bassa, man mano che ci si sposta ai livelli precedenti quindi l'accuracy tende a diminuire anche se vengono aggiunte informazioni utili al modello. Studi e ricerche effettuati affermano che all'aumentare del numero di layers oltre 20 questo problema si fa più presente[4].

Tra le metriche delle due reti è presente una coerenza nella proporzionalità dei valori, ciò ad indicare che apprendono allo stesso modo ma con efficacia diversa.

In riferimento al dominio in esame, vengono preferiti i falsi positivi in quanto verificare la presenza di falsi incendi è sostenibile rispetto alla non rilevazione di un vero incendio. Potrebbe perciò essere preferibile l'utilizzo della misura della recall come indice di performance della rete. Rispetto all'ambito di applicazione della rete, questa preferenza può cambiare. Se si è in un ambiente difficile da controllare, il rischio di un falso positivo può essere assunto.

Diversamente, in una zona molto più controllabile, è preferibile affidarsi ad uno strumento con una precisione più elevata di quella ottenuta in questo studio.

È inoltre rilevante sottolineare che nell'utilizzo reale della rete, le immagini provverranno da una fonte video continua, il che consentirà di diminuire la probabilità di errore, potendo interpolare le probabilità ottenute con sequenze di immagini adiacenti temporalmente.

## 6 SVILUPPI FUTURI

L'uso di un'altra rete come test empirico potrebbe evidenziare carenze e potenzialità della rete esposta in questo studio. Può essere meritevole di ulteriori studi l'indagine degli spike nelle performance della rete ad hoc sviluppata in questo paper. Inoltre è di notevole interesse indagare in merito al numero di immagini necessarie affinché un drone che sta sorvolando un incendio, inizi a classificarlo correttamente come tale. Infine, un incremento del dataset di addestramento, comprendente anche immagini di fumo senza presenza di fuoco, potrebbe comportare un incremento delle capacità di riconoscimento degli incendi della rete, come quello nella foto che segue.



**Figure 10.** Foto aerea di esempio per detection del fumo

## 7 CONCLUSIONI

I risultati ottenuti in generale sono incoraggianti, le prestazioni del sistema sono ritenute adeguate al task di interesse e si prospettano vari potenziali sviluppi futuri per rendere ancora più fruibile ed utilizzabile la rete ottenuta col presente studio anche in altri domini affini a quello qui analizzato. La rete sviluppata è di dimensioni sufficientemente ridotte da poter essere utilizzata su hardware a bassa potenza, ideale per l'ambito di applicazione di interesse su droni.

## REFERENCES

- [1] Hitesh Vaidya. How to write a neural network in tensorflow from scratch. <https://medium.com/analytics-vidhya/how-to-write-a-neural-network-in-tensorflow-from-scratch-without-using-keras-e056bb143d78>, 2021.
- [2] Fire detection from images.
- [3] D.Costa A.Giovannini. Sviluppo architettura con netron. <https://netron>, 2022.
- [4] H. Robbani and F. Arifin. Variations in the number of layers and the number of neurons in artificial neural networks: Case study of pattern recognition. 2019.